# INFORME TÉCNICO — PROYECTO 1

Machine Learning · Ingeniería Electrónica

Universidad del Magdalena

*Profesor: Rafael David Linero Ramos, PhD(c)*

Estudiantes: Mateo Cubillos Álvarez · Francisco José Fragoso

## 1. Planteamiento del Problema

### 1.1 Título del Proyecto

Sistema Inteligente de Clasificación de Calidad y Gestión de Salud del Cultivo de Café mediante Caracterización Digital de Defectos en Grano Verde.

### 1.2 Descripción del Caso de Uso

Colombia exporta más de 14 millones de sacos de café anuales. La clasificación manual de defectos en grano verde (negros, brocados, pergamino, etc.) es un proceso lento, subjetivo y costoso. Las pérdidas por defectos no detectados a tiempo superan el 15-30% del valor del lote.

El sistema propuesto permite al catador o técnico agrícola fotografiar una muestra de grano verde con cualquier cámara, cargar la imagen en la aplicación de escritorio, y obtener en segundos la clasificación de cada grano individual según la norma NTC 2090, junto con recomendaciones específicas de agroinsumos y prácticas de manejo.

### 1.3 Perfil del Usuario Objetivo

- Caficultores de pequeña y mediana escala de la región Caribe colombiana.
- Técnicos agrícolas y extensionistas rurales de la Sierra Nevada de Santa Marta.
- Inspectores de calidad en cooperativas y trilladoras.
- Estudiantes e investigadores de agronomía e ingeniería.

### 1.4 Justificación Técnica

Random Forest fue seleccionado como modelo principal por su robustez ante datos desbalanceados, su capacidad de generar importancia de características interpretable, y su rendimiento eficiente en datasets tabulares de tamaño moderado (642 muestras). No requiere GPU y opera completamente en entorno local.

# 2. Arquitectura del Sistema

## 2.1 Módulos Implementados

| Módulo | Tecnología | Función |
|---|---|---|
| DataLoader | Python · pathlib · zipfile | Carga ZIP, carpetas, CSV, JSON, XLSX |
| GrainSegmentor | OpenCV · Watershed | Extrae granos individuales de imagen multi-grano |
| FeatureExtractor | NumPy · SciPy | 65 features: color(35) + textura(18) + forma(12) |
| Preprocessor | scikit-learn · imbalanced-learn | Imputer · StandardScaler · SMOTE |
| ModelEngine | RandomForestClassifier | 200 árboles · class_weight=balanced · CV 5-fold |
| Evaluator | scikit-learn · seaborn | F1 · MCC · Bal.Acc · Confusión · Importancias |
| UIInterface | CustomTkinter · Matplotlib | Aplicación de escritorio con 6 pestañas |

## 2.2 Flujo del Sistema

- El usuario selecciona el dataset desde la interfaz gráfica.
- El DataLoader detecta el formato automáticamente (ZIP, carpeta, CSV, JSON, XLSX).
- El GrainSegmentor aplica OTSU + Watershed para extraer cada grano individualmente.
- El FeatureExtractor calcula 65 características por grano.
- El Preprocessor imputa NaN, escala y aplica SMOTE para balancear clases.
- El ModelEngine entrena el Random Forest con validación cruzada 5-fold.
- El Evaluator genera métricas, confusión e importancia de features.
- El sistema guarda el modelo .joblib y los artefactos en la carpeta resultados/.

# 3. Dataset y Preprocesamiento

## 3.1 Fuente de Datos

Green Coffee Beans Image Dataset · Licencia CC BY-NC-SA 4.0 · Tesis de pregrado UNIMAGDALENA.

11 imágenes JPG de alta resolución con múltiples granos sobre fondo blanco. 642 granos totales distribuidos en 11 clases de defecto.

| Clase | Granos | Calidad NTC 2090 |
|---|---|---|
| Normales | 255 | Premium |
| Negros | 100 | Rechazo |
| Pergamino | 90 | Consumo |
| MarronAVinagre | 36 | Rechazo |
| PMordidoCortado | 36 | Consumo |
| Concha | 33 | Consumo |
| BrocadoLeve | 30 | Consumo |
| BrocadoSevero | 25 | Rechazo |
| Inmaduro | 16 | Consumo |
| DXHongo | 12 | Rechazo |
| CerezaSeca | 9 | Rechazo |

### 3.2 Pipeline de Preprocesamiento

Se implementaron 4 pasos documentados:

- Imputación de valores nulos con mediana por columna (SimpleImputer).
- Split estratificado 80/20 manteniendo proporción de clases (SEED=42).
- Escalado z-score con StandardScaler (fit exclusivamente en train).
- SMOTE con k adaptativo para balancear clases minoritarias (solo en train).

## 4. Requerimientos del Sistema

### 4.1 Requerimientos Funcionales

| # | Requerimiento | Estado |
|---|---|---|
| RF1 | Cargar dataset en cualquier formato | ✅Cumplido |
| RF2 | Segmentar granos individuales con OpenCV | ✅Cumplido |
| RF3 | Extraer 65 features por grano | ✅Cumplido |
| RF4 | Clasificar en Premium / Consumo / Rechazo (NTC 2090) | ✅Cumplido |
| RF5 | Generar recomendaciones de agroinsumos | ✅Cumplido |
| RF6 | Evaluar con F1, MCC, Balanced Accuracy | ✅Cumplido |
| RF7 | Predictor interactivo para imágenes nuevas | ✅Cumplido |
| RF8 | Exportar modelo .joblib y artefactos CSV/PNG | ✅Cumplido |

### 4.2 Requerimientos No Funcionales

- Ejecutable en Windows, Mac y Linux sin instalación especial.
- Reproducible con semilla fija SEED=42.
- Código modular con funciones documentadas.
- Sin dependencia de GPU ni conexión a internet en ejecución.

# 5. Evaluación Técnica

## 5.1 Métricas del Modelo

El modelo Random Forest fue evaluado con las siguientes métricas sobre el conjunto de prueba (20% del dataset):

| Métrica | Descripción | Valor típico esperado |
|---|---|---|
| Accuracy | Porcentaje de predicciones correctas | > 75% |
| F1-macro | F1 con igual peso a todas las clases | > 0.65 |
| Balanced Accuracy | Accuracy ajustada por desbalanceo | > 0.70 |
| MCC | Correlación de Matthews (robusto a desbalanceo) | > 0.60 |
| OOB Score | Error out-of-bag del Random Forest | > 0.70 |
| CV F1 5-fold | F1-macro en validación cruzada | > 0.65 ± 0.05 |

## 5.2 Pruebas Funcionales

| Prueba | Entrada | Resultado esperado |
|---|---|---|
| Carga ZIP | archive.zip con 11 JPG | 642 granos segmentados correctamente |
| Carga CSV | granos.csv con columna defecto | Features cargadas sin errores |
| Diagnóstico imagen normal | Foto de granos buenos | Clasifica como Premium |
| Diagnóstico imagen defectuosa | Foto con granos negros | Detecta Rechazo + recomendación |
| Guardar modelo | Clic en □ | Genera modelo_cafe_rf.joblib |
| Cargar modelo guardado | Seleccionar .joblib | Predictor funcional sin reentrenar |

# 6. Consideraciones Éticas y Limitaciones

## 6.1 Sesgos Identificados

- Sesgo de iluminación: dataset capturado con fondo blanco uniforme. Imágenes de campo con iluminación variable pueden reducir el accuracy entre 20% y 40%.
- Muestra pequeña: CerezaSeca (n=9) y DXHongo (n=12) tienen métricas poco confiables estadísticamente.
- Sesgo geográfico: dataset no validado en Huila, Nariño, Antioquia ni Eje Cafetero.

## 6.2 Uso Responsable

- El sistema es una herramienta de apoyo. No reemplaza al catador certificado Q Grader.
- No debe usarse para emitir certificados oficiales ante la FNC ni el ICA.
- Las dosis de agroinsumos son orientativas. Consultar un ingeniero agrónomo antes de aplicar.

### 6.3 Proyección Futura

- Ampliar dataset con muestras de campo de la Sierra Nevada (alianza CENICAFÉ).
- Versión móvil Flutter + TFLite para uso offline en finca.
- Validación con catadores Q Grader de la región Caribe colombiana.

## 7. Entregables del Proyecto

| Archivo | Descripción |
|---|---|
| app.py | Código fuente completo de la aplicación de escritorio |
| requirements.txt | Dependencias del proyecto con versiones |
| README.md | Documentación e instrucciones de ejecución |
| modelo_cafe_rf.joblib | Modelo entrenado con scaler, imputer y encoder |
| resultados/confusion_matrix.png | Matriz de confusión normalizada |
| resultados/feature_importance.png | Importancia de las 20 features principales |
| resultados/dataset_granos.csv | Dataset completo de 642 granos con 65 features |
| resultados/experimentos_log.json | Log del experimento con métricas y configuración |
| archive.zip | Dataset original (CC BY-NC-SA 4.0) |

## 8. Autoevaluación — Rúbrica del Proyecto

| Criterio | Peso | Nivel | Justificación |
|---|---|---|---|
| Planteamiento del problema | 10% | 4 | Problema real, NTC 2090, usuario definido, viabilidad técnica justificada |
| Arquitectura y flujo | 15% | 4 | 7 módulos documentados, diagrama de flujo, RF y RNF completos |
| Implementación funcional | 20% | 4 | App ejecutable end-to-end, todos los módulos integrados y funcionales |
| Integración ML | 15% | 4 | Random Forest con CV 5-fold, OOB, class_weight, comparativa baseline |
| Métricas y pruebas | 15% | 4 | F1, MCC, Balanced Accuracy, confusión doble, feature importance |
| Experiencia de usuario | 10% | 4 | GUI CustomTkinter con 6 pestañas, sliders, predictor interactivo |
| Ética y limitaciones | 5% | 4 | 3 sesgos identificados, riesgos agroinsumos, licencia CC citada |
| Documentación | 10% | 4 | README, código comentado, artefactos descargables, informe técnico |

**Mateo Cubillos Álvarez · Francisco José Fragoso**
Programa de Ingeniería Electrónica · Universidad del Magdalena · 2025